

Projet - Réseau de neurones pour l'oral

Classification automatique de l'âge de locuteurs du corpus ESLO2

Alix Sirven-Vienot
M2 TAL parcours R&D
(Nanterre)

alix.sirven-vienot@sorbonne-nouvelle.fr

Lise Brisset
M2 TAL parcours R&D
(Sorbonne Nouvelle)

lise.brisset@sorbonne-nouvelle.fr

Introduction

Dans le cadre de se projet du cours de Réseau de neurones pour la reconnaissance de l'oral et applications linguistiques 2024-2025 (enseignants N. Audibert et C. Gendrot, Université Sorbonne Nouvelle), nous avons choisi de s'intéresser à la classification automatique de l'âge de segments de parole spontanée.

Ce travail est dans la continuité du mémoire de recherche de M2 d'Orane Dufour s'intitulant *Analyse acoustique, phonétique et neuronale de classes d'âge en parole spontanée* (Dufour, 2024). Notre objectif est de voir s'il est possible d'obtenir de meilleurs résultats que ceux obtenus dans les travaux d'Orane Dufour en utilisant des méthodes différentes toutes en reprenant d'une part la structure de son modèle afin que nos résultats soient dans certains cas comparables aux siens.

1 Méthodes

Afin de classifier automatiquement les classes d'âges nous avons d'abord décidé de prendre la même division en classes qu'Orane Dufour, c'est-à-dire trois classes d'âges qui sont *jeune*, *mid*, *vieux*, et qui correspondent respectivement aux délimitations d'âges *<30 ans*, *entre 30 et 60 ans compris* et *>60 ans*.

1.1 Présentation du corpus

Le corpus que nous avons utilisé est le corpus ESLO2 créé par le laboratoire de l'université d'Orléans (Corpus ESLO2, 2008). Nous avons travaillé plus précisément avec les enregistrements de paroles spontanées de trois modules ESLO2. Le module *Entretien* qui contient un total de 78 enregistrements de locuteurs différents. Le module *Entretiens jeunes* contenant 9 enregistrements de locuteurs différents ayant entre 18 et 25 ans. Et le module *Diachronie*, qui est composé de 7 enregistrements de locuteurs différents. Nous avons

donc un ensemble de 91 locuteurs. L'ensemble des modules ont été enregistrés avec deux outils d'enregistrements différents. Il pourrait être intéressant dans un travail futur de vérifier si le canal d'enregistrement n'influence pas les résultats de la classification.

1.2 Vectorisation

Nous avons vu en cours une technique très utilisée avec laquelle les réseaux de neurones sont performants. Il s'agit de donner en entrée du réseau des matrices correspondant aux images de spectrogramme des segments de parole courts. Cependant nous n'utiliserons pas cette technique dans ce projet. Notre camarade Orane Dufour avait vectoriser l'ensemble du corpus ESLO2 en utilisant la première couche du modèle Wav2Vec2 qui est celle qui encodent principalement des informations acoustiques et phonétiques, tandis que les couches plus profondes traitent des informations lexicales et sémantiques. Le modèle Wav2Vec2 est spécialisé dans la reconnaissance de la parole à partir de fichiers audio bruts, non annotés et non transcrits.

Nous avons pensé reproduire son expérience avec un autre type de vecteur sur les mêmes données et les mêmes catégories. Les vecteurs que nous avons choisis sont les X-vectors provenant de la librairie SpeechBrain (speechbrain, 2018). Les X-vectors pourraient être une méthode plus adaptée à notre tâche de classification car ils représentent un total de 512 caractéristiques audios qui capturent les informations discriminantes de la voix d'un locuteur. Ils sont connus pour être robustes face aux variations de l'environnement des différents enregistrements, ce qui semble adapté à notre corpus d'enregistrements de parole spontané. Les X-vectors sont aussi efficaces pour capturer des informations sur l'identité du locuteur comme son âge.

Les enregistrements des entretiens des 91 locuteurs de ESLO2 que nous avons utilisés ont été

préalablement segmentés par Orane Dufour. Cette segmentation a permis de distinguer les interventions du chercheur qui avait le rôle d'interviewer de celles du locuteur interviewé qui nous intéresse. De plus, les enregistrements des locuteurs ont été découpés en sections de 4 secondes. Ce sont donc ces sections de 4 secondes que nous avons vectorisées. Le nombre de segments des parole de 4 secondes par locuteur varie entre 111 et 1387. Tous ces segments avaient une fréquence d'échantillonnage de 44 100 Hz, ils ont donc été convertis en 16 000 Hz pour pouvoir être donnés en entrée des modèles. Nous avons un total cumulé sur tous les locuteurs de 46 974 fichiers vectorisés.


1.3 Description des modèles

Pour ce projet, nous avons choisi de tester deux modèles.

1.3.1 Modèle Orane

Le premier modèle que nous nommons *Orane* est un réseau de neurones qui reprend la même structure que le modèle utilisé par Orane Dufour sur ses vecteurs Wav2Vec2. Voici la structure de celui-ci :

Structure du Modèle Orane




La dernière couche dense du modèle renvoie en output des vecteurs de probabilité des classes pour chaque vecteur donné en input.

Tester un modèle basé sur la même structure que celle de notre camarade mais avec une vectorisation différente, nous permet d'analyser si la méthode de vectorisation influence les résultats et quelle méthode de vectorisation permet de mieux représenter l'âge.

1.3.2 Modèle CNN

Nous avons décidé de créer un second modèle qui soit un réseau de neurones convolutifs. Ce dernier n'ayant pas la même structure que le modèle *Orane* nous donne une autre chance d'obtenir de meilleurs résultats. Voici la structure du modèle que l'on nomme *CNN* :

Structure du Modèle CNN



Nous avons choisi cette deuxième structure de modèle car les CNN contiennent des couches de convolution et de pooling qui permettent de réduire la dimensionnalité des données tout en conservant les informations essentielles. Cela peut aider à éviter le surapprentissage et à améliorer la généralisation du modèle. De plus, en essayant différents types d'architecture de réseau de neurones, nous pouvons expérimenter différentes configurations et voir quel modèle est le plus adapté à notre tâche de classification.

2 Expériences

2.1 Datasets

En ce qui concerne les datasets, nous avons dans un premier temps divisé les données en deux catégories *Femme* et *Homme*. Les modèles ont été entraînés séparément sur les vecteurs des enregistrements des femmes et des hommes en raison

de leurs différences biologiques. Ceci entraîne des caractéristiques acoustiques différentes entre eux et impacterait les performances de nos modèles. Voici la figure 1 présentant la répartition des locuteurs par genre et par classe d'âge.




Figure 1: Répartition du nombre de locuteurs pour chaque genre

Dans un second temps nous avons voulu vérifier la répartition des segments de 4 secondes. Vous trouverez en Figure 2, la répartition des classes en fonction des genres de nos locuteurs dans l'ensemble des segments d'enregistrements de 4 secondes de notre corpus.




Figure 2: Répartition du nombre total de fichiers pour chaque genre

Nous pouvons observer que la répartition du nombre de fichiers est proportionnelle au nombre de locuteurs par catégorie d'âge chez les femmes. Il semble cependant y avoir un nombre démesuré de données dans la catégorie *mid* et un peu moins de données pour la catégorie *jeune* par rapport à la catégorie *vieux*. En comparaison avec les hommes, nous pouvons voir que les données sont moins proportionnelles entre le nombre de fichiers et le nombre de locuteurs par catégorie. En effet, il y a environ deux fois plus de fichiers dans les catégories *mid* et *vieux* que dans la catégorie *jeune*.

Les quantités de données dans les trois classes ne sont donc pas bien réparties. Nous avons tout

de même choisi de les garder comme elles sont en entraînement des modèles. Tout en étant attentives dans les résultats que nous obtiendrons.

En ce qui concerne la division train/test/val, nous avons choisi pour chaque modèle de genre, de prendre 70% des données en train, 20% en test et 10% en validation. Orane Dufour avait entraîné un modèle par locuteur, en ne prenant qu'un locuteur en test/val et tous les autres en entraînement, tout en séparant les locuteurs hommes et femmes. Par manque de temps, nous avons décidé de procéder différemment. Nous avons sélectionné un certain nombre de locuteurs pour l'entraînement, représentant environ 70% du total des fichiers. Le reste des locuteurs était mis en test/val (les fichiers de ces locuteurs ont été mélangés avant la répartition dans ces deux datasets). Le nombre de locuteurs pris en val/test variait donc proportionnellement au nombre de locuteurs par classe.

2.2 Résultats des modèles

2.2.1 Orane

a. Orane Femme

Dans le tableau ci-dessous (tableau 1), nous pouvons voir les résultats du modèle *Orane* pour le corpus des femmes.

Classe	Précision	Rappel	F1-Score
Jeune	0.812	0.580	0.677
Mid	0.520	0.740	0.611
Vieux	0.181	0.082	0.113
Accuracy		0.508	
Macro Avg	0.504	0.467	0.467
Weighted Avg	0.465	0.508	0.467

Table 1: Résultats du modèle *Orane* pour les femmes

La performance globale du modèle montre une accuracy à 50.8. La macro-avg a une précision de 0.504 et un rappel de 0.467, ces résultats suggèrent des performances plutôt équilibrées mais perfectibles. Pour ce qui est de l'analyse des classes, la classe d'âge *jeune* a une précision élevée (0.812), mais un rappel plus faible (0.580), ce qui indique que le modèle identifie bien les locuteurs jeunes mais manque certains éléments. La classe d'âge moyen a un rappel plutôt élevé (0.740) mais une précision plus faible (0.520), montrant une tendance à surclasser cette catégorie. La classe *vieux* a une performance globale faible avec un F1-score de seulement 0.113. Il s'agit d'une des classes ayant

un nombre minoritaire de données ce qui pourrait donc expliquer un score aussi bas.

b. Orane Homme

Classe	Précision	Rappel	F1-Score
Jeune	0.225	0.460	0.302
Mid	0.454	0.392	0.421
Vieux	0.854	0.510	0.639
Accuracy		0.440	
Macro Avg	0.511	0.454	0.454
Weighted Avg	0.534	0.440	0.465

Table 2: Résultats de classification du modèle Orane pour les hommes

Dans le tableau ci-dessus (tableau 2), nous pouvons voir les résultats du modèle *Orane* entraîné sur le corpus homme. Les performances globales de ce modèle pour le corpus des hommes sont plus basses que pour le corpus des femmes avec une accuracy de 44. Pour ce qui est de l’analyse des classes, la classe *jeune* a une faible précision (0.225) et un rappel modéré (0.46). Pour la classe d’âge moyen, le f1-score est relativement équilibré (0.421), mais inférieur à celui du corpus féminin. A l’inverse du corpus des femmes, la classe *vieux* est la classe la mieux reconnue avec une bonne précision (0.854) et un rappel plus modéré (0.510).

2.2.2 CNN

a. CNN Femme

Classe	Précision	Rappel	F1-Score
Jeune	0.759	0.666	0.710
Mid	0.528	0.631	0.575
Vieux	0.305	0.226	0.259
Accuracy		0.511	
Macro Avg	0.531	0.508	0.515
Weighted Avg	0.498	0.511	0.500

Table 3: Résultats du modèle CNN pour les femmes

Ce tableau présente les résultats obtenus avec le modèle *CNN* entraîné avec le corpus femme. Ce modèle a une accuracy de 51.1, une légère amélioration par rapport au modèle *Orane*. La macro-avg montre une augmentation des scores moyens, avec un F1-score de 0.515. Pour ce qui est des classes, la classe *jeune* a une bonne précision (0.759) et un bon rappel (0.666), ce qui montre une meilleure gestion de cette classe que les modèles précédents.

Pour la classe d’âge moyen, les performances sont légèrement inférieures à celle du modèle *Orane* (F1-score : 0.575). La classe *vieux* a toujours des scores faibles (F1-score : 0.259), indiquant que cette classe reste difficile à classer sûrement du à sa sous-représentation dans le corpus des femmes vis-à-vis des données de la classe *mid*.

b. CNN Homme

Classe	Précision	Rappel	F1-Score
Jeune	0.240	0.446	0.312
Mid	0.594	0.453	0.514
Vieux	0.801	0.710	0.753
Accuracy		0.529	
Macro Avg	0.545	0.536	0.526
Weighted Avg	0.592	0.529	0.549

Table 4: Résultats du modèle CNN pour les hommes.

Dans le tableau ci-dessus (tableau 4), nous pouvons voir les résultats du modèle *CNN* entraîné sur le corpus homme. Ce modèle donne les meilleurs résultats comparés aux autres modèles avec une accuracy de 52.4. Malgré cela, le déséquilibre des classes se voit particulièrement dans la différence entre la macro-avg (0.526) et la weighted-avg (0.549) de ce modèle. L’analyse des classes montre que la classe *jeune* est légèrement mieux reconnue qu’avec le modèle *Orane* avec un f1-score de 0.321. La classe d’âge moyen a une bonne performance globale avec 0.514. La classe *vieux*, quand à elle, a une bonne précision (0.801) et un bon rappel (0.710) démontrant une forte reconnaissance de cette classe.

Vous trouverez en annexes(5, 6, 3, 4), les courbes d’apprentissage Loss et Accuracy pour les deux modèles entraînés avec le corpus femme. Celles-ci sont très similaires aux courbes d’apprentissage des modèles entraînés avec le corpus homme. Nous pouvons voir que les progressions de nos différentes courbes d’apprentissage en fonction des epochs sont très éloignées des courbes de validations. Elles révèlent une difficulté de généralisation des classes par les modèles ce qui expliquerait les résultats moyens de l’ensemble de nos modèles. En effet, l’Accuracy des données de validation de nos modèles ne suit pas la progression de la courbe des données de train. Il en est de même pour les courbes de Loss, la valeur baisse lors des premières époques mais arrête sa progression rapidement en stagnant à une valeur qui n’est pas optimale.

Conclusions

En résumé, nos expériences ont montré que les modèles CNN offrent de meilleures performances, surtout pour la reconnaissance des voix masculines. Chez les femmes, l'écart est moins marqué mais ces modèles restent plus performants.

Concernant la classification par groupe d'âge, les voix de personnes âgées se sont avérées particulièrement difficiles à classer chez les femmes. Les hommes ont quant à eux obtenu de meilleures performances globales, en particulier pour la reconnaissance des voix de personnes âgées.

Nos résultats ne sont cependant pas directement comparables à ceux de notre camarade Orane Dufour (Dufour, 2024) car nos modèles n'ont pas été entraînés sur les mêmes divisions des données. De plus, notre camarade obtenait les mêmes courbes de progressions en fonction des époques.

Certaines pistes restent à creuser. Nous pourrions à la suite de ce projet, faire une classification de l'âge selon les mêmes critères sur les segments de silence afin de voir l'impact du canal d'enregistrement sur notre tâche de classification. Nous pourrions aussi additionner nos X-vecteurs à des vecteurs de type BERT des transcriptions de nos segments de 4 secondes afin de voir si l'ajout d'informations syntaxiques et lexicales améliore la reconnaissance de l'âge d'un locuteur.

Références

Orane Dufour. 2024. *Analyse acoustique, phonétique et neuronale de classes d'âge en parole spontanée*. Mémoire Master TAL.

Snyder, D., Garcia-Romero, D., McCree, A., Sell, G., Povey, D., Khudanpur, S.. 2018. *Spoken language recognition using X-vectors*. Odyssey 2018 (pp. 105–111).

Ravanelli, M., Parcollet, T., Plantinga, P., Rouhe, A., Cornell, S., Lugosch, L., Subakan, C., Dawalatabad, N., Heba, A., Zhong, J., Chou, J.-C., Yeh, S.-L., Fu, S.-W., Liao, C.-F., Rastorgueva, E., Grondin, F., Aris, W., Na, H., Gao, Y., De Mori, R., Bengio, Y.. 2018. *SpeechBrain: A general-purpose speech toolkit*. arXiv:2106.04624.

Corpus ESLO2. 2008. *Enquêtes Sociolinguistiques à Orléans 2*. Laboratoire Ligérien de Linguistique, Université d'Orléans. [En ligne] Disponible sur : <http://eslo.huma-num.fr/index.php/pagecorpus/pagepresentationcorpus>

Annexes




Figure 3: Accuracy pour le modèle Orane - femme




Figure 4: Loss pour le modèle Orane - femme




Figure 5: Accuracy pour le modèle CNN - femme




Figure 6: Loss pour le modèle CNN - femme